



深蓝学院
shenlanxueyuan.com

手写VIO大作业讲解



主讲人 张兵兵



题目

大作业为两个代码作业, 完成时间为三周:

1. 更优的优化策略,:

a. 选用更优的 LM 策略, 使得 VINS-Mono 在 MH-05 数据集上收敛速度更快或者精度更高.

b. 实现 dog-leg 算法替换 LM 算法, 并测试替换后的 VINS-Mono 在 MH-05 上算法精度.

详细的实验报告, 包括: 对迭代时间和精度进行评估, 其中精度评估可以采用 evo 工具(<https://github.com/MichaelGrupp/evo>) 对轨迹精度进行评估, 轨迹真值在 zip 中已给出.

2. 更快的 makehessian 矩阵

可以采用任何一种或多种加速方式 (如多线程, 如sse指令集等) 对信息矩阵的拼接函数加速, 并给出详细的实验对比报告.

- 第1题：更优的优化策略
- 第2题：更快的makehessian矩阵

第1题：更优的优化策略

- 改进的角度

- LM阻尼因子更新策略

- Dog Leg

- 其他改进的角度

- 限制步数

- 残差阈值

- 参数增量阈值

第1题：更优的优化策略

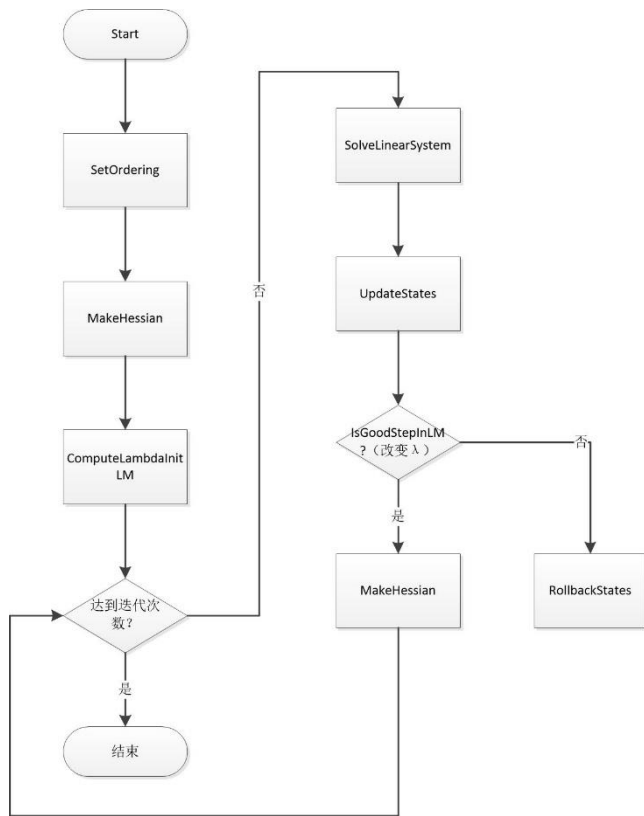
●回顾几种LM阻尼因子更新策略：

1. $\lambda_0 = \lambda_o$; λ_o is user-specified [8].
use eq'n (13) for \mathbf{h}_{lm} and eq'n (16) for ρ
if $\rho_i(\mathbf{h}) > \epsilon_4$: $\mathbf{p} \leftarrow \mathbf{p} + \mathbf{h}$; $\lambda_{i+1} = \max[\lambda_i/L_{\downarrow}, 10^{-7}]$;
otherwise: $\lambda_{i+1} = \min[\lambda_i L_{\uparrow}, 10^7]$;
2. $\lambda_0 = \lambda_o \max[\text{diag}[\mathbf{J}^T \mathbf{W} \mathbf{J}]]$; λ_o is user-specified.
use eq'n (12) for \mathbf{h}_{lm} and eq'n (15) for ρ
$$\alpha = \left(\left(\mathbf{J}^T \mathbf{W} (\mathbf{y} - \hat{\mathbf{y}}(\mathbf{p})) \right)^T \mathbf{h} \right) / \left((\chi^2(\mathbf{p} + \mathbf{h}) - \chi^2(\mathbf{p})) / 2 + 2 \left(\mathbf{J}^T \mathbf{W} (\mathbf{y} - \hat{\mathbf{y}}(\mathbf{p})) \right)^T \mathbf{h} \right)$$

if $\rho_i(\alpha \mathbf{h}) > \epsilon_4$: $\mathbf{p} \leftarrow \mathbf{p} + \alpha \mathbf{h}$; $\lambda_{i+1} = \max[\lambda_i / (1 + \alpha), 10^{-7}]$;
otherwise: $\lambda_{i+1} = \lambda_i + |\chi^2(\mathbf{p} + \alpha \mathbf{h}) - \chi^2(\mathbf{p})| / (2\alpha)$;
3. $\lambda_0 = \lambda_o \max[\text{diag}[\mathbf{J}^T \mathbf{W} \mathbf{J}]]$; λ_o is user-specified [9].
use eq'n (12) for \mathbf{h}_{lm} and eq'n (15) for ρ
if $\rho_i(\mathbf{h}) > \epsilon_4$: $\mathbf{p} \leftarrow \mathbf{p} + \mathbf{h}$; $\lambda_{i+1} = \lambda_i \max[1/3, 1 - (2\rho_i - 1)^3]$; $\nu_i = 2$;
otherwise: $\lambda_{i+1} = \lambda_i \nu_i$; $\nu_{i+1} = 2\nu_i$;

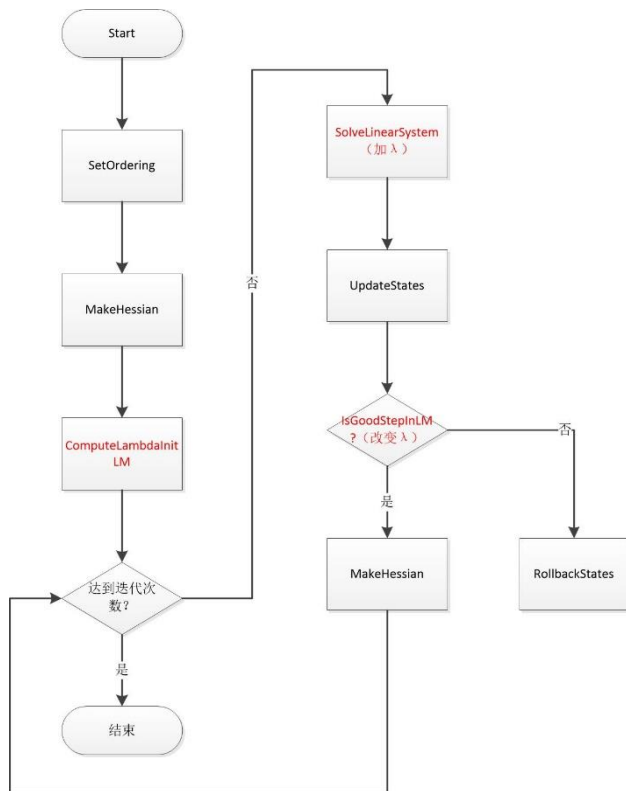
第1题：更优的优化策略

● 回顾代码



第1题：更优的优化策略

● 优化的几个地方



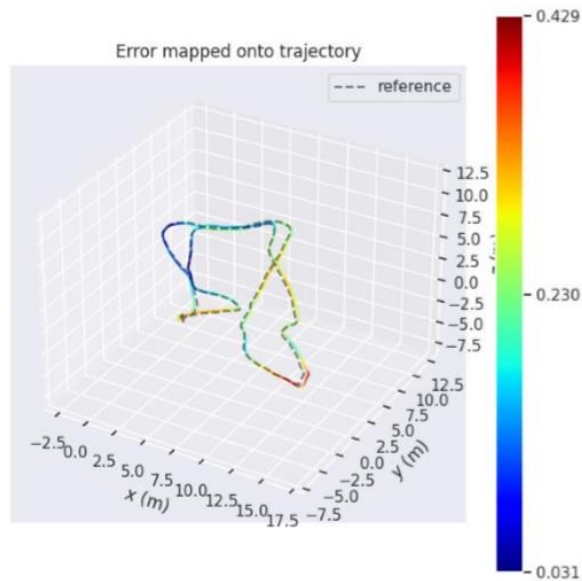

第1题：更优的优化策略

●对比

方法	初始化	求解方程	λ 变化比例
1	与 Hessian 矩阵无关	Hessian 对角线元素加上 λ *Hessian 对角线元素	固定
2	与 Hessian 矩阵有关	Hessian 对角线加上 λ	与 α 有关
3	与 Hessian 矩阵有关	Hessian 对角线加上 λ	与 ρ 有关


第1题：更优的优化策略

- 测试结果：方法1的精度较高



第1题：更优的优化策略

● Dog Leg



Dog Leg算法示意图^[1]

[1] Lourakis M, Argyros A A. Is Levenberg-Marquardt the Most Efficient Optimization Algorithm for Implementing Bundle Adjustment?[C]// 10th IEEE International Conference on Computer Vision (ICCV 2005), 17-20 October 2005, Beijing, China. IEEE, 2005.

第1题：更优的优化策略

●Dog Leg^[1]


- 属于信赖域 (Trust Region) 类优化算法
- 在以当前点为中心，半径 Δ 的区域（信赖域）内，将目标函数做二阶近似
- 分别计算最速下降法和高斯牛顿法的最优增量 δ_{sd} 和 δ_{gn} ，根据信赖域大小选择合适的增量

[1] Lourakis M, Argyros A A. Is Levenberg-Marquardt the Most Efficient Optimization Algorithm for Implementing Bundle Adjustment?[C]// 10th IEEE International Conference on Computer Vision (ICCV 2005), 17-20 October 2005, Beijing, China. IEEE, 2005.

第1题：更优的优化策略

●Dog Leg步骤^[1]

1. 计算最速下降法和高斯牛顿法的最优增量 δ_{sd} 和 δ_{gn}
2. 选取合适的增量 δ_{dl}
3. 更新信赖域半径 Δ



第1题：更优的优化策略

●Dog Leg步骤^[1]

1. 计算最速下降法和高斯牛顿法的最优增量 δ_{sd} 和 δ_{gn}

■ δ_{sd}

- $F(x + \Delta x) = \frac{1}{2} \|f(x + \Delta x)\|_2^2 \approx F(x) + J^\top f \Delta x + \frac{1}{2} \Delta x^\top J^\top J \Delta x, s. t. \|\Delta x\| \leq \Delta$
- 增量方向: $d = F'(x) = (J^\top f)^\top$
- 增量步长: $\frac{\partial F(x - \alpha d)}{\partial \alpha} = 0 \quad \alpha = \frac{(J^\top f)^\top J^\top f}{(J^\top f)^\top (J^\top J) J^\top f}$
- $\delta_{sd} \quad \delta_{sd} = \frac{-(J^\top f)^\top J^\top f}{(J^\top f)^\top (J^\top J) J^\top f} (J^\top f)^\top$ 对应代码 $\frac{b^\top b}{b^\top H b} b$

第1题：更优的优化策略

●Dog Leg步骤^[1]

1. 计算最速下降法和高斯牛顿法的最优增量 δ_{sd} 和 δ_{gn}


■ δ_{gn}

- $F(x + \Delta x) = \frac{1}{2} \|f(x + \Delta x)\|_2^2 \approx F(x) + J^T f \Delta x + \frac{1}{2} \Delta x^T J^T J \Delta x, s. t. \|\Delta x\| \leq \Delta$
- $J^T J \delta_{gn} = -J^T f$ 对应代码 $Hx = b$


第1题：更优的优化策略

● Dog Leg步骤^[1]


2. 选取合适的增量 δ_{dl}



$$\text{若 } \|\delta_{gn}\| \leq \Delta, \|\delta_{sd}\| \in \mathbb{R} \\ \delta_{dl} = \delta_{gn}$$



$$\text{若 } \|\delta_{gn}\| > \Delta, \|\delta_{sd}\| > \Delta \\ \delta_{dl} = \frac{\delta_{sd}}{\|\delta_{sd}\|} \Delta$$



$$\text{若 } \|\delta_{gn}\| > \Delta, \|\delta_{sd}\| \leq \Delta \\ \delta_{dl} = \delta_{sd} + \alpha(\delta_{gn} - \delta_{sd})$$

第1题：更优的优化策略

● Dog Leg步骤^[1]

2. 选取合适的增量 δ_{dl}

$$\delta_{dl} = \begin{cases} \kappa \delta_{sd} & 0 \leq \kappa \leq 1 \\ \delta_{sd} + (\kappa - 1)(\delta_{gn} - \delta_{sd}) & 1 \leq \kappa \leq 2 \end{cases}$$

- if $\|\delta_{gn}\| \leq \Delta$ $\kappa = 2$
- else if $\|\delta_{sd}\| \geq \Delta$ $\kappa = \frac{\Delta}{\|\delta_{sd}\|}$
- else $\|\delta_{sd}\| < \Delta$ $\kappa = ?$ $\|\delta_{sd} + (\kappa - 1)(\delta_{gn} - \delta_{sd})\| = \Delta$

第1题：更优的优化策略

●Dog Leg步骤^[1]

3. 更新信赖域半径 Δ

- 下降比计算 $\rho = \frac{F(x+\Delta x) - F(x)}{m_k(x+\Delta x) - m_k(x)}$
- if $\rho \leq 0.25$ (近似效果不好, 缩小信赖域) $\Delta = \frac{\Delta}{4}$
- else if $\rho \geq 0.75$ (近似效果好, 增大信赖域) $\Delta = \max\{\Delta, 3\|\delta_{dl}\|\}$

[1] Lourakis M, Argyros A A. Is Levenberg-Marquardt the Most Efficient Optimization Algorithm for Implementing Bundle Adjustment?[C]// 10th IEEE International Conference on Computer Vision (ICCV 2005), 17-20 October 2005, Beijing, China. IEEE, 2005.

第1题：更优的优化策略

- 其他改进的角度

- 限制步数

- 残差阈值

- 参数增量阈值

- 利用滑动窗口算法的性质，marginalize一帧后增加一帧，问题结构变化不大。因此可利用上一次求解的结果优化当前问题，比如上一次的结果作为当前的初值

第2题：更快的MakeHessian

- Hessian矩阵的拼接过程非常适合并行计算
- ▣ OpenMP最便捷，资料较多：<http://supercomputingblog.com/openmp/openmp-tutorial-the-basics/>
- ▣ SSE Instruction Set: Intel公司有效增强CPU浮点运算的能力的指令集：
<http://supercomputingblog.com/optimization/getting-started-with-sse-programming/>
- ▣ Nvidia CUDA 较复杂，可参考CUDA官方文档：<https://cuda-tutorial.readthedocs.io/en/latest/tutorials/tutorial01/>





深蓝学院
shenlanxueyuan.com

感谢各位聆听 !
Thanks for Listening

