

## 第 4 讲 基于滑动窗口算法的 VIO 系统：可观性和一致性

贺一家，高翔，崔华坤

- ① 从高斯分布到信息矩阵  
SLAM 和高斯分布  
从两个简单例子窥探协方差和信息矩阵
- ② 舒尔补应用：边际概率，条件概率  
舒尔补  
舒尔补与条件概率和边际概率  
总结
- ③ 滑动窗口算法  
图优化基础  
基于边际概率的滑动窗口算法
- ④ 滑动窗口中的 FEJ 算法  
滑动窗口算法的系统回顾及深入剖析  
系统可观性  
滑动窗口算法中存在的问题以及 FEJ 算法
- ⑤ 作业

# Section 1

## 从高斯分布到信息矩阵

# SLAM 问题概率建模

考虑某个状态  $\xi$ ，以及一次与该变量相关的观测  $\mathbf{r}_i$ 。由于噪声的存在，观测服从概率分布  $p(\mathbf{r}_i|\xi)$ 。

多次观测时，各个测量值相互独立，则多个测量  $\mathbf{r} = (\mathbf{r}_1, \dots, \mathbf{r}_n)^\top$  构建的似然概率为：

$$p(\mathbf{r}|\xi) = \prod_i p(\mathbf{r}_i|\xi) \quad (1)$$

如果知道机器人状态的先验信息  $p(\xi)$ ，如 GPS，车轮码盘信息等，则根据 Bayes 法则，有后验概率：

$$p(\xi|\mathbf{r}) = \frac{p(\mathbf{r}|\xi)p(\xi)}{p(\mathbf{r})} \quad (2)$$

通过最大后验估计，获得系统状态的最优估计：

$$\xi_{\text{MAP}} = \arg \max_{\xi} p(\xi|\mathbf{r}) \quad (3)$$

# SLAM 问题求解

后验公式 (2) 中分母跟状态量无关，舍弃。最大后验变成了：

$$\xi_{\text{MAP}} = \arg \max_{\xi} \prod_i p(\mathbf{r}_i | \xi) p(\xi) \quad (4)$$

即

$$\xi_{\text{MAP}} = \arg \min_{\xi} \left[ - \sum_i \log p(\mathbf{r}_i | \xi) - \log p(\xi) \right] \quad (5)$$

如果假设观测值服从多元高斯分布：

$$p(\mathbf{r}_i | \xi) = \mathcal{N}(\mu_i, \Sigma_i), p(\xi) = \mathcal{N}(\mu_{\xi}, \Sigma_{\xi}) \quad (6)$$

则有：

$$\xi_{\text{MAP}} = \underset{\xi}{\operatorname{argmin}} \sum_i \|\mathbf{r}_i - \mu_i\|_{\Sigma_i}^2 + \|\xi - \mu_{\xi}\|_{\Sigma_{\xi}}^2 \quad (7)$$

这个最小二乘的求解可以使用上节课的解法：

$$\mathbf{J}^{\top} \Sigma^{-1} \mathbf{J} \delta \xi = -\mathbf{J}^{\top} \Sigma^{-1} \mathbf{r} \quad (8)$$

# 高斯分布和协方差矩阵

## 多元高斯分布

零均值的多元高斯分布有如下概率形式：

$$p(\mathbf{x}) = \frac{1}{Z} \exp\left(-\frac{1}{2}\mathbf{x}^\top \Sigma^{-1} \mathbf{x}\right)$$

其中  $\Sigma$  是协方差矩阵，协方差矩阵的逆记作  $\Lambda = \Sigma^{-1}$ 。

比如变量  $\mathbf{X}$  为三维的变量时，协方差矩阵为：

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} & \Sigma_{13} \\ \Sigma_{21} & \Sigma_{22} & \Sigma_{23} \\ \Sigma_{31} & \Sigma_{32} & \Sigma_{33} \end{bmatrix} \quad (9)$$

其中  $\Sigma_{ij} = E(x_i x_j)$  为对应元素求期望。

## 本节课的主题



当维数变大时，求解计算量巨大。如何优雅的从多元高斯分布中丢弃变量？

$$p(\mathbf{x}, \mathbf{y}) \rightarrow p(\mathbf{x}) \text{ or } p(\mathbf{y})$$

## toy example 1


## 样例

设  $x_2$  为室外的温度,  $x_1, x_3$  分别为房间 1 和房间 3 的室内温度:

$$\begin{aligned}x_2 &= v_2 \\x_1 &= w_1 x_2 + v_1 \\x_3 &= w_3 x_2 + v_3\end{aligned}\tag{10}$$

其中,  $v_i$  相互独立, 且各自服从零均值, 协方差为  $\sigma_i^2$  的高斯分布。

这两个例子来源于文档<sup>1</sup>



<sup>1</sup>David Mackay. "The humble Gaussian distribution". In: (2006).

# 样例对应的状态量协方差矩阵

从上述关系，根据协方差公式的计算方式，我们可以写出  $x$  的协方差矩阵，先从对角元素开始计算：

$$\begin{aligned}
 \Sigma_{11} &= E(x_1 x_1) = E((w_1 v_2 + v_1)(w_1 v_2 + v_1)) \\
 &= w_1^2 E(v_2^2) + 2w_1 E(v_1 v_2) + E(v_1^2) \\
 &= w_1^2 \sigma_2^2 + \sigma_1^2
 \end{aligned} \tag{11}$$

同理有  $\Sigma_{22} = \sigma_2^2$ ,  $\Sigma_{33} = w_3^2 \sigma_2^2 + \sigma_3^2$ . 对于协方差矩阵的非对角元素：

$$\begin{aligned}
 \Sigma_{12} &= E(x_1 x_2) = E((w_1 v_2 + v_1)v_2) = w_1 \sigma_2^2 \\
 \Sigma_{13} &= E((w_1 v_2 + v_1)(w_3 v_2 + v_3)) = w_1 w_3 \sigma_2^2
 \end{aligned} \tag{12}$$

以此类推，可以得到整个协方差矩阵：

$$\Sigma = \begin{bmatrix} w_1^2 \sigma_2^2 + \sigma_1^2 & w_1 \sigma_2^2 & w_1 w_3 \sigma_2^2 \\ w_1 \sigma_2^2 & \sigma_2^2 & w_3 \sigma_2^2 \\ w_1 w_3 \sigma_2^2 & w_3 \sigma_2^2 & w_3^2 \sigma_2^2 + \sigma_3^2 \end{bmatrix} \tag{13}$$



# 对应的协方差矩阵的逆呢？

通过计算联合高斯分布从而得到协方差矩阵的逆：

$$\begin{aligned}
 p(x_1, x_2, x_3) &= p(x_2)p(x_1|x_2)p(x_3|x_2) \\
 &= \frac{1}{Z_2} \exp\left(-\frac{x_2^2}{2\sigma_2^2}\right) \frac{1}{Z_1} \exp\left(-\frac{(x_1 - w_1 x_2)^2}{2\sigma_1^2}\right) \frac{1}{Z_3} \exp\left(-\frac{(x_3 - w_3 x_2)^2}{2\sigma_3^2}\right)
 \end{aligned} \tag{14}$$

利用指数性质求出联合概率分布：

$$\begin{aligned}
 p(x_1, x_2, x_3) &= \frac{1}{Z} \exp\left(-\frac{x_2^2}{2\sigma_2^2} - \frac{(x_1 - w_1 x_2)^2}{2\sigma_1^2} - \frac{(x_3 - w_3 x_2)^2}{2\sigma_3^2}\right) \\
 &= \frac{1}{Z} \exp\left(-x_2^2 \left[\frac{1}{2\sigma_2^2} + \frac{w_1^2}{2\sigma_1^2} + \frac{w_3^2}{2\sigma_3^2}\right] - x_1^2 \frac{1}{2\sigma_1^2} + 2x_1 x_2 \frac{w_1}{2\sigma_1^2} - x_3^2 \frac{1}{2\sigma_3^2} + 2x_3 x_2 \frac{w_3}{2\sigma_3^2}\right) \\
 &= \frac{1}{Z} \exp\left(-\frac{1}{2} \begin{bmatrix} x_1 & x_2 & x_3 \end{bmatrix} \begin{bmatrix} \frac{1}{\sigma_1^2} & -\frac{w_1}{\sigma_1^2} & 0 \\ -\frac{w_1}{\sigma_1^2} & \frac{w_1^2}{\sigma_1^2} + \frac{1}{\sigma_2^2} + \frac{w_3^2}{\sigma_3^2} & -\frac{w_3}{\sigma_3^2} \\ 0 & -\frac{w_3}{\sigma_3^2} & \frac{1}{\sigma_3^2} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}\right)
 \end{aligned} \tag{15}$$

## 样例 1 对应的信息矩阵

由此得到协方差矩阵的逆，即信息矩阵：

$$\Lambda = \Sigma^{-1} = \begin{bmatrix} \frac{1}{\sigma_1^2} & -\frac{w_1}{\sigma_1^2} & 0 \\ -\frac{w_1}{\sigma_1^2} & \frac{w_1^2}{\sigma_1^2} + \frac{1}{\sigma_2^2} + \frac{w_3^2}{\sigma_3^2} & -\frac{w_3}{\sigma_3^2} \\ 0 & -\frac{w_3}{\sigma_3^2} & \frac{1}{\sigma_3^2} \end{bmatrix} \quad (16)$$

**注意：**信息矩阵中有两个元素为 0，它有什么具体含义呢？协方差逆矩阵中如果坐标为  $(i, j)$  的元素为 0，表示元素  $i$  和  $j$  关于其他变量条件独立，上面的例子中意味着变量  $x_1$  和  $x_3$  关于  $x_2$  条件独立。

### 协方差元素 vs 信息矩阵元素

假设室内温度和室外温度正相关 ( $w_i > 0$ )，

- 协方差中非对角元素  $\Sigma_{ij} > 0$  表示两变量是正相关。
- 信息矩阵中非对角元素为负数，甚至为 0。 $\Lambda_{12} < 0$  表示在变量  $x_3$  发生的条件下，元素  $x_1$  和  $x_2$  正相关。

## toy example 2

### 样例


比如特征三角化，两个相机 pose 得到特征三维坐标：

$$x_2 = w_1 x_1 + w_3 x_3 + v_2 \quad (17)$$

同理，根据协方差矩阵的定义，可以得到协方差矩阵：

$$\Sigma = \begin{bmatrix} \sigma_1^2 & w_1 \sigma_1^2 & 0 \\ w_1 \sigma_1^2 & \sigma_2^2 + w_1^2 \sigma_1^2 + w_3^2 \sigma_3^2 & w_3 \sigma_3^2 \\ 0 & w_3 \sigma_3^2 & \sigma_3^2 \end{bmatrix}$$

协方差矩阵中非对角元素为 0 表示变量之间没有相关性。这是否意味着信息矩阵中也会为 0 呢？



## 样例 2 协方差矩阵的逆

按照例子 1 中的方式，求取协方差矩阵的逆：

$$\begin{aligned}
 p(x_1, x_2, x_3) &= p(x_1)p(x_3)p(x_2|x_1, x_3) \\
 &= \frac{1}{Z_1} \exp\left(-\frac{x_1^2}{2\sigma_1^2}\right) \frac{1}{Z_3} \exp\left(-\frac{x_3^2}{2\sigma_3^2}\right) \frac{1}{Z_2} \exp\left(-\frac{(x_2 - w_1x_1 - w_3x_3)^2}{2\sigma_2^2}\right)
 \end{aligned} \tag{18}$$

将变量整成向量形式：

$$\begin{aligned}
 p(x_1, x_2, x_3) &= \frac{1}{Z} \exp\left(-\frac{x_1^2}{2\sigma_1^2} - \frac{x_3^2}{2\sigma_3^2} - \frac{(x_2 - w_1x_1 - w_3x_3)^2}{2\sigma_2^2}\right) \\
 &= \frac{1}{Z} \exp\left(-\frac{1}{2} \begin{bmatrix} x_1 & x_2 & x_3 \end{bmatrix} \begin{bmatrix} \frac{1}{\sigma_1^2} + \frac{w_1^2}{\sigma_2^2} & -\frac{w_1}{\sigma_2^2} & \frac{w_1w_3}{\sigma_2^2} \\ -\frac{w_1}{\sigma_2^2} & \frac{1}{\sigma_2^2} & -\frac{w_3}{\sigma_2^2} \\ \frac{w_1w_3}{\sigma_2^2} & -\frac{w_3}{\sigma_2^2} & \frac{1}{\sigma_3^2} + \frac{w_3^2}{\sigma_2^2} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}\right)
 \end{aligned} \tag{19}$$

## 样例 2 中的有趣现象

从上面推导出的信息矩阵来看,

- 虽然  $x_1$  和  $x_3$  不相关, 但是不说明他们的信息矩阵对应元素  $\Lambda_{13}$  为 0。
- 恰恰信息矩阵中  $\Lambda_{13} > 0$ , 表示的是在变量  $x_2$  发生的条件下, 变量  $x_1, x_3$  成负相关。
- 对应上面的例子即  $x_2$  为常数, 如果  $x_1$  大, 则  $x_3$  小。

**样例的意义:** 非常有助于我们了解 SLAM 的信息矩阵  $H$  的组成。

**疑问:** 如果我们移除变量, 信息矩阵或协方差矩阵如何变化呢?

# toy example 1 中去除变量 $x_3$

## 协方差如何变化？


利用协方差的计算公式可知， $x_1, x_2$  计算协方差时跟  $x_3$ ，并无关系，所以

$$\Sigma = \begin{bmatrix} w_1^2 \sigma_2^2 + \sigma_1^2 & w_1 \sigma_2^2 & w_1 w_3 \sigma_2^2 \\ w_1 \sigma_2^2 & \sigma_2^2 & w_3 \sigma_2^2 \\ w_1 w_3 \sigma_2^2 & w_3 \sigma_2^2 & w_3^2 \sigma_2^2 + \sigma_3^2 \end{bmatrix} \quad (20)$$

就能得到去除  $x_3$  后的协方差矩阵：

$$\Sigma_2 = \begin{bmatrix} w_1^2 \sigma_2^2 + \sigma_1^2 & w_1 \sigma_2^2 \\ w_1 \sigma_2^2 & \sigma_2^2 \end{bmatrix} \quad (21)$$

这两个例子来源于文档<sup>2</sup>



<sup>2</sup>David Mackay. "The humble Gaussian distribution". In: (2006).

## toy example 1 中去除变量 $x_3$

### 信息矩阵如何变化？

同样，我们只需要把信息矩阵公式 (16) 中  $x_3$  对应的部分 (蓝色) 去掉就可以：

$$\Sigma^{-1} = \begin{bmatrix} \frac{1}{\sigma_1^2} & -\frac{w_1}{\sigma_1^2} & \theta \\ -\frac{w_1}{\sigma_1^2} & \frac{w_1^2}{\sigma_1^2} + \frac{1}{\sigma_2^2} + \frac{w_3^2}{\sigma_3^2} & -\frac{w_3}{\sigma_3^2} \\ \theta & -\frac{w_3}{\sigma_3^2} & \frac{1}{\sigma_3^2} \end{bmatrix} \quad (22)$$

从而得到：

$$\Sigma_2^{-1} = \begin{bmatrix} \frac{1}{\sigma_1^2} & -\frac{w_1}{\sigma_1^2} \\ -\frac{w_1}{\sigma_1^2} & \frac{w_1^2}{\sigma_1^2} + \frac{1}{\sigma_2^2} \end{bmatrix} \quad (23)$$

是不是非常简单？但是问题在于：实际操作过程中并不会有这种颜色标记。

这时，需要引入 marginalization (边缘化) 和 Schur's complement (舒尔补) 来解决这个问题。

## Section 2

# 舒尔补应用：边际概率，条件概率



# 舒尔补的概念

## 舒尔补定义

给定任意的矩阵块  $M$ ，如下所示：

$$M = \begin{bmatrix} A & B \\ C & D \end{bmatrix} \quad (24)$$

- 如果，矩阵块  $D$  是可逆的，则  $A - BD^{-1}C$  称之为  $D$  关于  $M$  的舒尔补。
- 如果，矩阵块  $A$  是可逆的，则  $D - CA^{-1}B$  称之为  $A$  关于  $M$  的舒尔补。

更多定义参见 [wiki](#)<sup>3</sup>.

<sup>3</sup>Wiki. Schur Complement. [https://en.wikipedia.org/wiki/Schur\\_complement](https://en.wikipedia.org/wiki/Schur_complement)

# 舒尔补的来由

将  $M$  矩阵变成上三角或者下三角形过程中，都会遇到舒尔补：

$$\begin{aligned} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{CA}^{-1} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix} &= \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{0} & \Delta_{\mathbf{A}} \end{bmatrix} \\ \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{I} & -\mathbf{A}^{-1}\mathbf{B} \\ \mathbf{0} & \mathbf{I} \end{bmatrix} &= \begin{bmatrix} \mathbf{A} & \mathbf{0} \\ \mathbf{C} & \Delta_{\mathbf{A}} \end{bmatrix} \end{aligned} \quad (25)$$

其中： $\Delta_{\mathbf{A}} = \mathbf{D} - \mathbf{CA}^{-1}\mathbf{B}$ 。联合起来，将  $M$  变形成对角形：

$$\begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{CA}^{-1} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{I} & -\mathbf{A}^{-1}\mathbf{B} \\ \mathbf{0} & \mathbf{I} \end{bmatrix} = \begin{bmatrix} \mathbf{A} & \mathbf{0} \\ \mathbf{0} & \Delta_{\mathbf{A}} \end{bmatrix} \quad (26)$$

反过来，我们又能从对角形恢复成矩阵  $M$ ：

$$\begin{bmatrix} \mathbf{I} & \mathbf{0} \\ \mathbf{CA}^{-1} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{A} & \mathbf{0} \\ \mathbf{0} & \Delta_{\mathbf{A}} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{A}^{-1}\mathbf{B} \\ \mathbf{0} & \mathbf{I} \end{bmatrix} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix} \quad (27)$$

# 使用舒尔补分解的好处

## 快速求解矩阵 $M$ 的逆

矩阵  $M$  可写成：

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix} = \begin{bmatrix} I & 0 \\ CA^{-1} & I \end{bmatrix} \begin{bmatrix} A & 0 \\ 0 & \Delta_A \end{bmatrix} \begin{bmatrix} I & A^{-1}B \\ 0 & I \end{bmatrix} \quad (28)$$

由此可得矩阵  $M$  的逆：

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix}^{-1} = \begin{bmatrix} I & -A^{-1}B \\ 0 & I \end{bmatrix} \begin{bmatrix} A^{-1} & 0 \\ 0 & \Delta_A^{-1} \end{bmatrix} \begin{bmatrix} I & 0 \\ -CA^{-1} & I \end{bmatrix} \quad (29)$$

因为：

$$\begin{bmatrix} I & -A^{-1}B \\ 0 & I \end{bmatrix} \begin{bmatrix} I & A^{-1}B \\ 0 & I \end{bmatrix} = I \quad (30)$$

这个快速分解有什么好处呢？

# 舒尔补应用于多元高斯分布

## toy example

假设多元变量  $\mathbf{x}$  服从零均值高斯分布，且由两部分组成： $\mathbf{x} = \begin{bmatrix} a \\ b \end{bmatrix}$ ，  
变量之间构成的协方差矩阵为：

$$\mathbf{K} = \begin{bmatrix} A & C^\top \\ C & D \end{bmatrix}$$

其中  $A = \text{cov}(a, a)$ ,  $D = \text{cov}(b, b)$ ,  $C = \text{cov}(a, b)$ . 由此变量  $\mathbf{x}$  的概率分布为：

$$P(a, b) = P(a)P(b|a) \propto \exp \left( -\frac{1}{2} \begin{bmatrix} a \\ b \end{bmatrix}^\top \begin{bmatrix} A & C^\top \\ C & D \end{bmatrix}^{-1} \begin{bmatrix} a \\ b \end{bmatrix} \right) \quad (31)$$

利用舒尔补一节公式(29)，对高斯分布进行分解，得<sup>4</sup>

$$\begin{aligned}
 & P(a, b) \\
 & \propto \exp \left( -\frac{1}{2} \begin{bmatrix} a \\ b \end{bmatrix}^\top \begin{bmatrix} A & C^\top \\ C & D \end{bmatrix}^{-1} \begin{bmatrix} a \\ b \end{bmatrix} \right) \\
 & \propto \exp \left( -\frac{1}{2} \begin{bmatrix} a \\ b \end{bmatrix}^\top \begin{bmatrix} I & -A^{-1}C^\top \\ 0 & I \end{bmatrix} \begin{bmatrix} A^{-1} & 0 \\ 0 & \Delta_A^{-1} \end{bmatrix} \begin{bmatrix} I & 0 \\ -CA^{-1} & I \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} \right) \\
 & \propto \exp \left( -\frac{1}{2} \begin{bmatrix} a^\top & (b - CA^{-1}a)^\top \end{bmatrix} \begin{bmatrix} A^{-1} & 0 \\ 0 & \Delta_A^{-1} \end{bmatrix} \begin{bmatrix} a \\ b - CA^{-1}a \end{bmatrix} \right) \\
 & \propto \exp \left( -\frac{1}{2} (a^\top A^{-1}a) + (b - CA^{-1}a)^\top \Delta_A^{-1} (b - CA^{-1}a) \right) \\
 & \propto \underbrace{\exp \left( -\frac{1}{2} a^\top A^{-1}a \right)}_{p(a)} \underbrace{\exp \left( -\frac{1}{2} (b - CA^{-1}a)^\top \Delta_A^{-1} (b - CA^{-1}a) \right)}_{p(b|a)}
 \end{aligned} \tag{32}$$

这意味着我们能从多元高斯分布  $P(a, b)$  中分解得到**边际概率**  $p(a)$  和**条件概率**  $p(b|a)$ 。

<sup>4</sup>Huang. Conditional and marginal distributions of a multivariate Gaussian. <https://gbhqed.wordpress.com/2010/02/21/conditional-and-marginal-distributions-of-a-multivariate-gaussian/>

# 关于 $P(a)$ , $P(b|a)$ 的协方差矩阵

## $P(a)$ 的启示

$$\begin{aligned} P(a) &= \int_b P(a, b) \\ P(a) &\propto \exp\left(-\frac{1}{2}a^\top A^{-1}a\right) \sim \mathcal{N}(0, A) \end{aligned} \quad (33)$$

启示：边际概率的协方差就是从联合分布中取对应的矩阵块就行了。

## $P(b|a)$ 的启示

$$P(b|a) \propto \exp\left(-\frac{1}{2}\left(b - CA^{-1}a\right)^\top \Delta_A^{-1}\left(b - CA^{-1}a\right)\right) \quad (34)$$

启示： $P(b|a) \sim \mathcal{N}(CA^{-1}a, \Delta_A)$ 。协方差变为  $a$  对应的舒尔补，均值也变了。

疑问三连：信息矩阵也是这样的吗？如果不是， $P(a)$  的信息矩阵如何算？ $P(b|a)$  的呢？

# 关于 $P(a)$ , $P(b|a)$ 的信息矩阵

为什么要讨论  $P(a)$ ,  $P(b|a)$  的信息矩阵？

因为基于优化的 SLAM 问题中，我们往往直接操作的是信息矩阵，而不是协方差矩阵。所以，有必要知道边际概率，条件概率的信息矩阵是何形式。

$P(a)$ ,  $P(b|a)$  的信息矩阵

假设我们已知信息矩阵：

$$\begin{bmatrix} A & C^T \\ C & D \end{bmatrix}^{-1} = \begin{bmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{bmatrix} \quad (35)$$

另外，由公式 (29) 可知，协方差矩阵各块和信息矩阵之间有：

$$\begin{bmatrix} A & C^T \\ C & D \end{bmatrix}^{-1} = \begin{bmatrix} A^{-1} + A^{-1}C^T\Delta_A^{-1}CA^{-1} & -A^{-1}C^T\Delta_A^{-1} \\ -\Delta_A^{-1}CA^{-1} & \Delta_A^{-1} \end{bmatrix} \triangleq \begin{bmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{bmatrix} \quad (36)$$

### $P(a)$ , $P(b|a)$ 的信息矩阵

由条件概率  $P(b|a)$  的协方差为  $\Delta_A$  以及公式(36)，易得其信息矩阵为：

$$\Delta_A^{-1} = \Lambda_{bb} \quad (37)$$

由边际概率  $P(a)$  的协方差为  $A$  以及公式(36)，易得其信息矩阵为：

$$A^{-1} = \Lambda_{aa} - \Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba} \quad (38)$$



# 回顾样例

## 回顾 toy example 1 中去除变量 $x_3$ 的操作

$$\Sigma^{-1} = \begin{bmatrix} \frac{1}{\sigma_1^2} & \Lambda_{aa} & -\frac{w_1}{\sigma_1^2} & \Lambda_{ab}^0 \\ -\frac{w_1}{\sigma_1^2} & \frac{w_1^2}{\sigma_1^2} + \frac{1}{\sigma_2^2} + \frac{w_3^2}{\sigma_3^2} & -\frac{w_3}{\sigma_3^2} & -\frac{w_3}{\sigma_3^2} \\ 0 & \Lambda_{ba} & -\frac{w_3}{\sigma_3^2} & \Lambda_{bb}^1 \end{bmatrix}$$

从联合分布  $P(x_1, x_2, x_3)$  中 marg 掉变量  $x_3$ ，即  $P(x_1, x_2)$  对应的信息矩阵可以用公式(38)得到。

$$\begin{aligned} \mathbf{K}_2^{-1} &= \Lambda_{aa} - \Lambda_{ab} \Lambda_{bb}^{-1} \Lambda_{ba} \\ &= \Lambda_{aa} - \begin{bmatrix} 0 \\ -\frac{w_3}{\sigma_3^2} \end{bmatrix} \sigma_3^2 \begin{bmatrix} 0 & -\frac{w_3}{\sigma_3^2} \end{bmatrix} \\ &= \Lambda_{aa} - \begin{bmatrix} 0 & 0 \\ 0 & \frac{w_3^2}{\sigma_3^2} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sigma_1^2} & -\frac{w_1}{\sigma_1^2} \\ -\frac{w_1}{\sigma_1^2} & \frac{w_1^2}{\sigma_1^2} + \frac{1}{\sigma_2^2} \end{bmatrix} \end{aligned} \quad (39)$$

# 总结

边际概率对于协方差矩阵的操作是很容易的，但不好操作信息矩阵。条件概率恰好相反，对于信息矩阵容易操作，不好操作协方差矩阵。对于非零均值的高斯分布，表格总结如下<sup>5</sup>，可课后自己证明：

$$P(\mathbf{a}, \mathbf{b}) = \mathcal{N} \left( \begin{bmatrix} \boldsymbol{\mu}_a \\ \boldsymbol{\mu}_b \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{aa} & \boldsymbol{\Sigma}_{ab} \\ \boldsymbol{\Sigma}_{ba} & \boldsymbol{\Sigma}_{bb} \end{bmatrix} \right) = \mathcal{N}^{-1} \left( \begin{bmatrix} \boldsymbol{\eta}_a \\ \boldsymbol{\eta}_b \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Lambda}_{aa} & \boldsymbol{\Lambda}_{ab} \\ \boldsymbol{\Lambda}_{ba} & \boldsymbol{\Lambda}_{bb} \end{bmatrix} \right) \quad (40)$$

	边际概率 $p(\mathbf{a}) = \int p(\mathbf{a}, \mathbf{b}) d\mathbf{b}$	条件概率 $p(\mathbf{a} \mathbf{b}) = p(\mathbf{a}, \mathbf{b})/p(\mathbf{b})$
协方差矩阵	$\boldsymbol{\mu} = \boldsymbol{\mu}_a$ $\boldsymbol{\Sigma} = \boldsymbol{\Sigma}_{aa}$	$\boldsymbol{\mu}' = \boldsymbol{\mu}_a + \boldsymbol{\Sigma}_{ab}\boldsymbol{\Sigma}_{bb}^{-1}(\mathbf{b} - \boldsymbol{\mu}_b)$ $\boldsymbol{\Sigma}' = \boldsymbol{\Sigma}_{aa} - \boldsymbol{\Sigma}_{ab}\boldsymbol{\Sigma}_{bb}^{-1}\boldsymbol{\Sigma}_{ba}$
信息矩阵	$\boldsymbol{\eta} = \boldsymbol{\eta}_a - \boldsymbol{\Lambda}_{ab}\boldsymbol{\Lambda}_{bb}^{-1}\boldsymbol{\eta}_b$ $\boldsymbol{\Lambda} = \boldsymbol{\Lambda}_{aa} - \boldsymbol{\Lambda}_{ab}\boldsymbol{\Lambda}_{bb}^{-1}\boldsymbol{\Lambda}_{ba}$	$\boldsymbol{\eta}' = \boldsymbol{\eta}_a - \boldsymbol{\Lambda}_{ab}\boldsymbol{b}$ $\boldsymbol{\Lambda}' = \boldsymbol{\Lambda}_{aa}$

<sup>5</sup>Matthew R Walter, Ryan M Eustice, and John J Leonard. "Exactly sparse extended information filters for feature-based SLAM". In: *The International Journal of Robotics Research* 26.4 (2007), pp. 335+359. 

## Section 3

# 滑动窗口算法

# 最小二乘的图表示

## toy example 3

有如下最小二乘系统，对应的图模型如有图所示：

$$\xi = \underset{\xi}{\operatorname{argmin}} \frac{1}{2} \sum_i \|\mathbf{r}_i\|_{\Sigma_i}^2 \quad (41)$$

其中

$$\xi = \begin{bmatrix} \xi_1 \\ \xi_2 \\ \dots \\ \xi_6 \end{bmatrix}, \mathbf{r} = \begin{bmatrix} \mathbf{r}_{12} \\ \mathbf{r}_{13} \\ \mathbf{r}_{14} \\ \mathbf{r}_{15} \\ \mathbf{r}_{56} \end{bmatrix} \quad (42)$$



- 圆圈：表示顶点，需要优化估计的变量.
- 边：表示顶点之间构建的残差。有一元边（只连一个顶点），二元边，多元边...

# 最小二乘问题信息矩阵的构成

上述最小二乘问题，对应的高斯牛顿求解为：

$$\underbrace{\mathbf{J}^\top \Sigma^{-1} \mathbf{J}}_{\mathbf{H} \text{ or } \Lambda} \delta \xi = \underbrace{-\mathbf{J}^\top \Sigma^{-1} \mathbf{r}}_{\mathbf{b}} \quad (43)$$

注意，这里的  $\Lambda = \Sigma_{new}^{-1} \neq \Sigma^{-1}$  反应的是方程解的方差，而  $\Sigma^{-1}$  是残差的方差，两者含义不同。另外，公式中的雅克比矩阵为：

$$\mathbf{J} = \frac{\partial \mathbf{r}}{\partial \xi} = \begin{bmatrix} \frac{\partial \mathbf{r}_{12}}{\partial \xi} \\ \frac{\partial \mathbf{r}_{13}}{\partial \xi} \\ \frac{\partial \mathbf{r}_{14}}{\partial \xi} \\ \frac{\partial \mathbf{r}_{15}}{\partial \xi} \\ \frac{\partial \mathbf{r}_{56}}{\partial \xi} \end{bmatrix} = \begin{bmatrix} \mathbf{J}_1 \\ \mathbf{J}_2 \\ \mathbf{J}_3 \\ \mathbf{J}_4 \\ \mathbf{J}_5 \end{bmatrix}, \quad \mathbf{J}^\top = \begin{bmatrix} \mathbf{J}_1^\top & \mathbf{J}_2^\top & \mathbf{J}_3^\top & \mathbf{J}_4^\top & \mathbf{J}_5^\top \end{bmatrix} \quad (44)$$

矩阵乘法公式(43)可以写成连加：

$$\sum_{i=1}^5 \mathbf{J}_i^\top \Sigma_i^{-1} \mathbf{J}_i \delta \xi = - \sum_{i=1}^5 \mathbf{J}_i^\top \Sigma_i^{-1} \mathbf{r}_i \quad (45)$$

# 信息矩阵的稀疏性

## 雅克比矩阵，信息矩阵的稀疏性


由于每个残差只和某几个状态量有关，因此，雅克比矩阵求导时，无关项的雅克比为 0。比如

$$\begin{aligned}
 \mathbf{J}_2 &= \frac{\partial \mathbf{r}_{13}}{\partial \boldsymbol{\xi}} = \begin{bmatrix} \frac{\partial \mathbf{r}_{13}}{\partial \xi_1} & 0 & \frac{\partial \mathbf{r}_{13}}{\partial \xi_3} & 0 & 0 & 0 \end{bmatrix} \\
 \mathbf{\Lambda}_2 &= \mathbf{J}_2^\top \boldsymbol{\Sigma}_2^{-1} \mathbf{J}_2 = \begin{bmatrix} \left(\frac{\partial \mathbf{r}_{13}}{\partial \xi_1}\right)^\top \boldsymbol{\Sigma}_2^{-1} \frac{\partial \mathbf{r}_{13}}{\partial \xi_1} & 0 & \left(\frac{\partial \mathbf{r}_{13}}{\partial \xi_1}\right)^\top \boldsymbol{\Sigma}_2^{-1} \frac{\partial \mathbf{r}_{13}}{\partial \xi_3} & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ \left(\frac{\partial \mathbf{r}_{13}}{\partial \xi_3}\right)^\top \boldsymbol{\Sigma}_2^{-1} \frac{\partial \mathbf{r}_{13}}{\partial \xi_1} & 0 & \left(\frac{\partial \mathbf{r}_{13}}{\partial \xi_3}\right)^\top \boldsymbol{\Sigma}_2^{-1} \frac{\partial \mathbf{r}_{13}}{\partial \xi_3} & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}
 \end{aligned}
 \tag{46}$$

同理，可以计算  $\mathbf{\Lambda}_1, \mathbf{\Lambda}_3, \mathbf{\Lambda}_4, \mathbf{\Lambda}_5$ ，并且也是稀疏的。

# 信息矩阵组装过程的可视化

将五个残差的信息矩阵加起来，得到样例最终的信息矩阵  $\Lambda$ ，可视化如下：



# 基于边际概率的滑动窗口算法

## 为什么 SLAM 需要滑动窗口算法？

- 随着 VSLAM 系统不断往新环境探索，就会有新的相机姿态以及看到新的环境特征，最小二乘残差就会越来越多，信息矩阵越来越大，计算量将不断增加。
- 为了保持优化变量的个数在一定范围内，需要使用滑动窗口算法动态增加或移除优化变量。

## 滑动窗口算法大致流程

- ① 增加新的变量进入最小二乘系统优化
- ② 如果变量数目达到了一定的维度，则移除老的变量。
- ③ SLAM 系统不断循环前面两步


疑问：怎么移除老的变量？直接丢弃这些变量吗？



## 利用边际概率移除老的变量

直接丢弃变量和对应的测量值，会损失信息。正确的做法是使用边际概率，将丢弃变量所携带的信息传递给剩余变量。

下图为 toy example 3 中使用边际概率移除变量  $\xi_1$ ，信息矩阵的变化过程<sup>6</sup>：




**思考：**如果是直接丢弃，信息矩阵如何变化？用边际概率来操作又会带来什么问题？


<sup>6</sup>Matthew R Walter, Ryan M Eustice, and John J Leonard. "Exactly sparse extended information filters for feature-based SLAM". In: *The International Journal of Robotics Research* 26.4 (2007), pp. 335-359.

## toy example 4

如下图优化系统中，随着  $x_{t+1}$  的进入，变量  $x_t$  被移除<sup>7</sup>。



**marginalization 会使得信息矩阵变稠密！原先条件独立的变量，可能变得相关。**


<sup>7</sup>Matthew R Walter, Ryan M Eustice, and John J Leonard. "Exactly sparse extended information filters for feature-based SLAM". In: *The International Journal of Robotics Research* 26.4 (2007), pp. 335-359. 

## Section 4

# 滑动窗口中的 FEJ 算法

toy example 3 再移除变量  $\xi_1$  后加入新变量

- 新的变量  $\xi_7$  跟老的变量  $\xi_2$  之间存在观测信息，能构建残差  $r_{27}$ 。图模型如右图所示。
- 新残差加上之前 marg 留下的信息，构建新的最小二乘系统，对应的信息矩阵的变化如下图所示：



$$\Lambda \rightarrow \Lambda' + \Lambda_6 = \Lambda_{new}$$

The diagram illustrates the update of the information matrix  $\Lambda$  when a new variable  $\xi_7$  is added. The matrices are represented as 7x7 grids with columns labeled  $\xi_2, \xi_3, \xi_4, \xi_5, \xi_6, \xi_7$ .


- $\Lambda$ : A 6x6 block of blue squares in the top-left corner, with the rest of the grid white.
- $\Lambda'$ : A 7x7 grid where the 6x6 blue block from  $\Lambda$  is in the top-left, and the new column  $\xi_7$  has blue squares in rows 2 through 6.
- $\Lambda_6$ : A 7x7 grid where the new column  $\xi_7$  has red squares in rows 1 and 7, and the rest is white.
- $\Lambda_{new}$ : The result of adding  $\Lambda'$  and  $\Lambda_6$ . It has the 6x6 blue block from  $\Lambda$ , the new column  $\xi_7$  with blue squares in rows 2-6 and red squares in rows 1 and 7, and the rest is white.

注意： $\xi_2$  自身的信息矩阵由两部分组成，这会使得系统存在潜在风险。

# 系统回顾 toy example 3

## toy example 3

- ① 如右图所示，在  $t \in [0, k]s$  时刻，系统中状态量为  $\xi_i, i \in [1, 6]$ 。第  $k'$  时刻，加入新的观测和状态量  $\xi_7$ 。
- ② 在第  $k$  时刻，最小二乘优化完以后，marg 掉变量  $\xi_1$ 。被 marg 的状态量记为  $x_m$ ，剩余的变量  $\xi_i, i \in [2, 5]$  记为  $x_r$ 。
- ③ marg 发生以后， $x_m$  所有的变量以及对应的测量将被丢弃。同时，这部分信息通过 marg 操作传递给了保留变量  $x_r$ 。marg 变量的信息跟  $\xi_6$  不相关。
- ④ 第  $k'$  时刻，加入新的状态量  $\xi_7$  (记作  $x_n$ ) 以及对应的观测，开始新一轮最小二乘优化。



- 红色为被 marg 变量以及测量约束。
- 绿色为跟 marg 变量有关的保留变量。
- 蓝色为和 marg 变量无关联的变量。

## marg 发生后，留下的到底是什么信息？

marg 前，变量  $\mathbf{x}_m$  以及对应测量  $\mathcal{S}_m$  构建的最小二乘信息矩阵为：

$$\begin{aligned} \mathbf{b}_m(k) &= \begin{bmatrix} \mathbf{b}_{mm}(k) \\ \mathbf{b}_{mr}(k) \end{bmatrix} = - \sum_{(i,j) \in \mathcal{S}_m} \mathbf{J}_{ij}^\top(k) \boldsymbol{\Sigma}_{ij}^{-1} \mathbf{r}_{ij} \\ \boldsymbol{\Lambda}_m(k) &= \begin{bmatrix} \boldsymbol{\Lambda}_{mm}(k) & \boldsymbol{\Lambda}_{mr}(k) \\ \boldsymbol{\Lambda}_{rm}(k) & \boldsymbol{\Lambda}_{rr}(k) \end{bmatrix} = \sum_{(i,j) \in \mathcal{S}_m} \mathbf{J}_{ij}^\top(k) \boldsymbol{\Sigma}_{ij}^{-1} \mathbf{J}_{ij}(k) \end{aligned} \quad (47)$$

marg 后，变量  $\mathbf{x}_m$  的测量信息传递给了变量  $\mathbf{x}_r$ ：

$$\begin{aligned} \mathbf{b}_p(k) &= \mathbf{b}_{mr}(k) - \boldsymbol{\Lambda}_{rm}(k) \boldsymbol{\Lambda}_{mm}^{-1}(k) \mathbf{b}_{mm}(k) \\ \boldsymbol{\Lambda}_p(k) &= \boldsymbol{\Lambda}_{rr}(k) - \boldsymbol{\Lambda}_{rm}(k) \boldsymbol{\Lambda}_{mm}^{-1}(k) \boldsymbol{\Lambda}_{mr}(k) \end{aligned} \quad (48)$$

下标  $p$  表示 prior. 即这些信息将构建一个关于  $\mathbf{x}_r$  的先验信息。

### 先验

我们可以从  $\mathbf{b}_p(k), \boldsymbol{\Lambda}_p(k)$  中反解出一个残差  $\mathbf{r}_p(k)$  和对应的雅克比矩阵  $\mathbf{J}_p(k)$ . 需要注意的是，随着变量  $\mathbf{x}_r(k)$  的后续不断优化变化，残差  $\mathbf{r}_p(k)$  或者  $\mathbf{b}_p(k)$  也将跟着变化，但雅克比  $\mathbf{J}_p(k)$  则固定不变了。

# 新测量信息和旧测量信息构建新的系统

在  $k'$  时刻, 新残差  $\mathbf{r}_{27}$  和先验信息  $\mathbf{b}_p(k), \Lambda_p(k)$  以及残差  $\mathbf{r}_{56}$  构建新的最小二乘问题,  $\mathbf{J}_p(k)$  和  $\mathbf{r}_p(k)$  为先验部分对应的雅克比和残差:

$$\begin{aligned}\mathbf{b}(k') &= \Pi^\top \mathbf{J}_p(k) \mathbf{r}_p(k') - \sum_{(i,j) \in S_a(k')} \mathbf{J}_{ij}^\top(k') \Sigma_{ij}^{-1} \mathbf{r}_{ij}(k') \\ \Lambda(k') &= \Pi^\top \Lambda_p(k) \Pi + \sum_{(i,j) \in S_a(k')} \mathbf{J}_{ij}^\top(k') \Sigma_{ij}^{-1} \mathbf{J}_{ij}(k')\end{aligned}\quad (49)$$

其中  $\Pi = \begin{bmatrix} \mathbf{I}_{\dim \mathbf{x}_r} & \mathbf{0} \end{bmatrix}$  用来将矩阵的维度进行扩张。  $S_a$  用来表示除被 marg 掉的测量以外的其他测量, 如  $\mathbf{r}_{56}, \mathbf{r}_{27}$ 。

## 出现的问题

- 由于被 marg 的变量以及对应的测量已被丢弃, 先验信息  $\Lambda_p(k)$  中关于  $\mathbf{x}_r$  的雅克比在后续求解中没法更新。
- 但  $\mathbf{x}_r$  中的部分变量还跟其他残差有联系, 如  $\xi_2, \xi_5$ 。这些残差如  $\mathbf{r}_{27}$  对  $\xi_2$  的雅克比会随着  $\xi_2$  的迭代更新而不断在最新的线性化点处计算。

# 信息矩阵的零空间变化

## 滑动窗口算法导致的问题

滑动窗口算法优化的时候，信息矩阵如公式(49)变成了两部分，且这两部分计算雅克比时的线性化点不同。这可能会导致信息矩阵的零空间发生变化，从而在求解时引入错误信息。

比如：求解单目 SLAM 进行 Bundle Adjustment 优化时，问题对应的信息矩阵  $\Lambda$  不满秩，对应的零空间为  $N$ ，用高斯牛顿求解时有

$$\begin{aligned}\Lambda \delta \mathbf{x} &= \mathbf{b} \\ \Lambda \delta \mathbf{x} + \Lambda \mathbf{N} &= \mathbf{b}\end{aligned}\tag{50}$$


咦，增量  $\delta x$  在零空间维度下变化，并不会改变我们的残差。这意味着系统可以有多个满足最小化损失函数的解  $\mathbf{x}$ 。



# toy example


## Windowed, real-time optimization: Consistency.

(for now, let's assume we have initializations, and know which points to use and where they are visible.)




$$E = E_1 + E_2$$

$$= (xy - 1)^2 + (xy - 1)^2$$




$$E'_1 = E_1$$

Lin. around (0.5, 1.4)



$$E'_2 = E_2$$

Lin. around (1.2, 0.5)



$$E' = E'_1 + E'_2$$

**nullspace disappears!**

never combine linearizations around different linearization points,  
especially in the presence of non-linear nullspaces!

It will render unobservable dimensions observable, and corrupt the system.

多个解的问题，变成了一个确定解。不可观的变量，变成了可观的。

## 可观性的一种定义

对于测量系统  $\mathbf{z} = h(\boldsymbol{\theta}) + \varepsilon$ , 其中  $\mathbf{z} \in \mathbb{R}^n$  为测量值,  $\boldsymbol{\theta} \in \mathbb{R}^d$  为系统状态量,  $\varepsilon$  为测量噪声向量。  $h(\cdot)$  是个非线性函数, 将状态量映射成测量。对于理想数据, 如果以下条件成立, 则系统状态量  $\boldsymbol{\theta}$  可观:


$$\forall \boldsymbol{\theta}, \forall \boldsymbol{\theta}' \in \mathbb{R}^d, \{\boldsymbol{\theta} \neq \boldsymbol{\theta}'\} \Rightarrow \{h(\boldsymbol{\theta}) \neq h(\boldsymbol{\theta}')\} \quad (51)$$

更多定义见论文<sup>8</sup>

对于 SLAM 系统而言 (如单目 VO), 当我们改变状态量时, 测量不变意味着损失函数不会改变, 更意味着求解最小二乘时对应的信息矩阵  $\Lambda$  存在着零空间。

<sup>8</sup>Claude Jauffret. "Observability and Fisher information matrix in nonlinear regression". In: *IEEE Transactions on Aerospace and Electronic Systems* 43.2 (2007), pp. 756–759.

单目 SLAM 系统 7 自由度不可观：6 自由度姿态 + 尺度。



单目 + IMU 系统是 4 自由度不可观：yaw 角 + 3 自由度位置不可观。  
roll 和 pitch 由于重力的存在而可观，尺度因子由于加速度计的存在而可观。

## 滑动窗口中的问题

滑动窗口算法中，对于同一个变量，不同残差对其计算雅克比矩阵时线性化点可能不一致，导致信息矩阵可以分成两部分，相当于在信息矩阵中多加了一些信息，使得其零空间出现了变化。

## 解决办法：First Estimated Jacobian

FEJ 算法：不同残差对同一个状态求雅克比时，线性化点必须一致。这样就能避免零空间退化而使得不可观变量变得可观。

论文推荐<sup>9</sup>

比如：toy example 3 中计算  $r_{27}$  对  $\xi_2$  的雅克比时， $\xi_2$  的线性化点必须和  $r_{12}$  对其求导时一致。


<sup>9</sup>Tue-Cuong Dong-Si and Anastasios I Mourikis. "Consistency analysis for sliding-window visual odometry". In: *2012 IEEE International Conference on Robotics and Automation*. IEEE, 2012, pp. 5202–5209. 

## Section 5

# 作业

## 作业

- ① 某时刻，SLAM 系统中相机和路标点的观测关系如下图所示，其中  $\xi$  表示相机姿态， $L$  表示观测到的路标点。当路标点  $L$  表示在世界坐标系下时，第  $k$  个路标被第  $i$  时刻的相机观测到，重投影误差为  $r(\xi_i, L_k)$ 。另外，相邻相机之间存在运动约束，如 IMU 或者轮速计等约束。



- 1 请绘制上述系统的信息矩阵  $\Lambda$ .
  - 2 请绘制相机  $\xi_1$  被 marg 以后的信息矩阵  $\Lambda'$ .
- ② 阅读《Relationship between the Hessian and Covariance Matrix for Gaussian Random Variables》. 证明信息矩阵和协方差的逆之间的关系。
- ③ 请补充作业代码中单目 Bundle Adjustment 信息矩阵的计算，并输出正确的结果。正确的结果为：奇异值最后 7 维接近于 0，表明零空间的维度为 7.